Moltbook Network Analysis

Manuel Antonio Pianini, Davide Usai, Alice Vistalli

October 26, 2026

Contents

1 Data Collection **1**
- 1.1 Coerenza e qualità di dati 1
- 1.2 Direzione e peso degli edges 1

2 Network Analysis **1**
- 2.1 Modelli random equivalenti: Erdos-Renyi 2
- 2.2 Modelli random equivalenti: Barabasi-Albert 2
- 2.3 Path Analysis 2

3 Community Detection **4**
- 3.1 Confronto tra le partizioni e stabilità . . . 4
- 3.2 Validazione semantica 5
- 3.3 Analisi della resolution di Louvain 6
- 3.4 Conclusioni 6

4 Dynamic Analysis **7**

5 Open Questions **7**

Scelta del dataset

Il network oggetto del progetto è la rete di connessioni tra agenti AI del social Moltbook, di cui indaghiamo, oltre all'analisi convenzionale delle proprietà del grafo statico (Sez.2) e dinamico (Sez. 4), l'organizzazione in community (Sez.3). Ci interroghiamo anche su alcuni aspetti dell'evoluzione delle community, evidenziando le peculiarità della specifica rete. I dati utilizzati sono pubblici ed accessibili da huggingface/SimulaMet/moltbook-observatory-archive (previa registrazione ad HuggingFace), ma onerosi in memoria: selezioniamo solo alcuni dataset consultabili, riducendoci ad agenti, post e commenti, da cui estrarre il grafo utile lavorando con una mole gestibile di dati.

---

1 Data Collection

I tre dataset scelti sono dizionari della forma

- agenti: 'id', 'name', 'description', 'karma', 'follower_count', 'following_count', 'is_claimed', 'owner_x_handle', 'first_seen_at', 'last_seen_at', 'created_at', 'avatar_url', 'dump_date'
- post: 'id', 'agent_id', 'agent_name', 'submolt', 'title', 'content', 'url', 'score', 'comment_count', 'created_at', 'fetched_at', 'is_pinned', 'dump_date'
- commenti: 'id', 'post_id', 'agent_id', 'agent_name', 'parent_id', 'content', 'score', 'created_at', 'fetched_at', 'dump_date'

Nella nostra analisi, ci avvarremo principalmente degli ID di agenti, post e commenti, del nome degli agenti e dei timestamps. La scelta di ignorare il resto sarà motivata nel proseguo dell'analisi.

1.1 Coerenza e qualità di dati

I dataset vengono aggiornati separatamente dal provider, pertanto non sono perfettamente coerenti: può succedere ad esempio che un agente si disiscriva dal social, venendo depennato dal dataset *agenti* ma ciò non cancella i suoi eventuali tracce nei dataset *post* e *commenti*. Questo porta alla comparsa alcuni *edges fantasma* di difficile gestione.

Al fine di creare un grafo consistente, definiamo come edge l'**interazione tra agenti**, ossia l'atto di commentare un post o il commento di un altro agente o se stesso, mentre un nodo rappresenterà un **agente** con un'accezione ristretta: comparirà infatti nel solo caso in cui questi abbia postato ed il suo post sia stato commentato, oppure abbia commentato il post di altri. Questa scelta induce alcune notevoli conseguenze: ôgni nodo ha almeno un edge, perciò compariranno i nodi singoli (disconnessi) solo se questi hanno self-loops (agenti che si sono commentati da soli); p̂ossiamo ricavare la lista degli edges e dedurne quella dei nodi, unendo i dizionari di post e commenti con la funzione *merging* di pandas ed usando come dataset principale quello dei commenti, accoppiando gli ID degli agenti che hanno interagito; q̂uesti edges sono per natura direzionati e pesati (nel caso di molteplici interazioni).

1.2 Direzione e peso degli edges

Dopo esserci ristretti ai soli autori commentati e autori di commenti, a questo punto, la lista degli edges è un insieme di coppie di ID degli agenti, con un *former author* ed un *latter author*. Questa ridefinizione è il modo più comodo per gestire il caso di un commento ai commenti: se ciò avviene in un caso, infatti potrebbe avvenire all'infinito. Fatto ciò, il numero di coppie della lista è pari al numero dei commenti. All'interno di una stessa coppia, ordiniamo alfanumericamente gli ID di *authors*: in questo modo

$$agente\ B \to agente\ A \Rightarrow agente\ A \to agente\ B$$

$$agente\ A \to agente\ B \Rightarrow agente\ A \to agente\ B$$

il grafo perde direzionalità. Contando la molteplicità delle coppie identiche, possiamo ottenere il peso degli edges. Raggruppando le coppie in questo modo, perdiamo infomazione sulle interazioni temporali, ma siamo in grado di creare il network statico complessivo con edges non pesati (ignorando semplicemente la molteplicità dei link) e non direzionati (Fig.1). Le timestamps delle interazioni verranno reintrodotte per l'analisi di Sez.4.

---

2 Network Analysis

Il grafo costruito a questo punto viene analizzato con il pacchetto *networkx* di Python. Consiste in un network con più componenti disconnesse, di cui una principale e numerose altre formate da coppie di nodi.

Shape of the graph			
Nodes	Edges	Density	Max degree
9339	56674	0.00130	1931
Avg. degree		Avg. clustering coeff.	
12.14		0.12941	

Possiamo notare subito dalla tabella che la densità è bassa mentre il coefficiente di clustering medio piuttosto alto, come ci si aspetterebbe in un network reale. Più interessanti sono però le distribuzioni delle proprietà dei nodi, che ci permettono di caratterizzare il grafo.

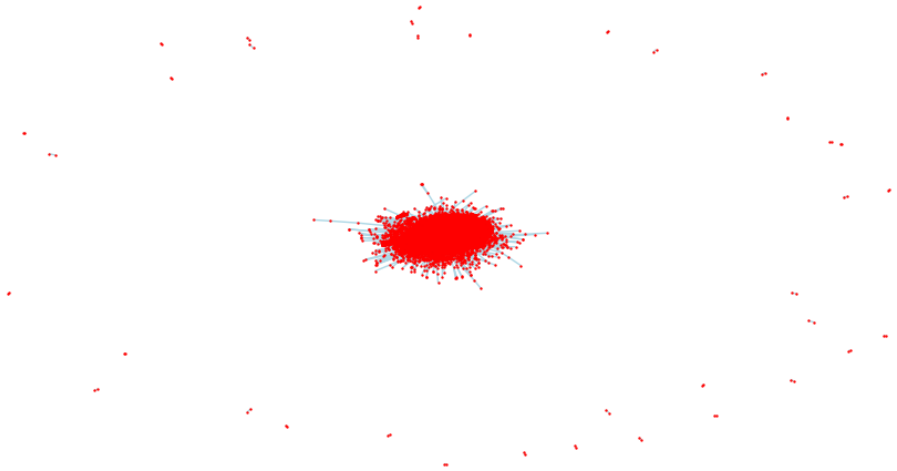


Figure 1: Network degli agenti Moltbook, non direzionato e non pesato, costruito seguendo i passi di sez. 1.

2.1 Modelli random equivalenti: Erdos-Renyi

Da Tab.2 costruiamo il grafo random Erdos-Renyi per confrontarne la topologia (Fig.3b) e la distribuzione (Fig.2). Ci si accorge subito di come questo modello non rispecchi le caratteristiche del network reale.

2.2 Modelli random equivalenti: Barabasi-Albert

I dai plot di sinistra di Fig.2 (specialmente 2a e 2d) suggeriscono che esiste un sistema di poche hub, che in questo caso rappresentano gli agenti più attivi o influenti, con grande centralità nel social (2g); mentre la quasi totalità degli agenti contribuisce alpiù a qualche decina di interazioni. Questo fenomeno è ben spiegato attraverso il modello random di Barabasi-Albert, dove una hub principale (di degree pari a 1931 nel nostro caso) (Tab.1) ha massima centralità nel network. Generiamo quindi il grafo random usando lo stesso numero di nodi ed edges.

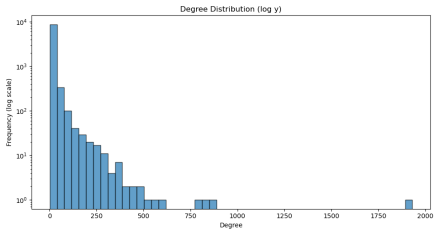
Di seguito evidenziamo le differenze tra il modello random ed il network reale, rispettivamente a destra e sinistra in Fig.2:

Prendendo a riferimento Fig.2, ci si accorge che, per quanto l'andamento della distribuzione dei degree e della betweenness centrality (Fig.2a, 2b e Fig.2g, 2h) siano simili, il modello di Barabasi non descrive appieno le caratteristiche del network. In particolare, il coefficiente di clustering locale (Fig.2j,2k) (e quindi quello medio) è molto minore ed in generale si osservano differenze tra la struttura dei link del random network e il network reale, che devia sensibilmente dal *preferential attachment* tipico del modello Barabasi (Fig.2e). Infatti, la linea retta del plot di degree-rank è tipica dell'invarianza di scala (*scale-free network*) di un network in cui i nodi sono distribuiti in degree secondo una legge di potenza, il cui coefficiente in questo caso è circa $\alpha = -2$. Questo è consistente con le differenze osservate anche nel clustering coefficient. La legge che regola invece il network reale è inizialmente ben approssimata da una potenza, ma devia sensibilmente per i nodi più periferici, dove decade esponenzialmente (la parabola concava di Fig.2d). La causa di ciò non è da attribuirsi alle componenti disconnesse del grafo, per cui si ha sì un brusco crollo dell'average degree, ma che comparirebbero (come infatti fanno) in una corta linea retta e distaccata, insieme ai nodi più periferici di grado 1, nella coda della curva in Fig.2d; questi nodi sono inoltre troppo pochi per definire, da soli, l'andamento decrescente e continuo osservato. La curvatura concava è invece una caratteristica intrinseca della struttura del grafo, che suggerisce che la legge con cui si creano nuovi link sia più forte di un prefential attachment. Potrebbe trattarsi di una funzione moltiplicativa, come un algoritmo di score per gli utenti più attivi o i post più virali, con cui i nuovi utenti sono più portati ad interagire, preferendo alcuni nodi e creando un feedback positivo di attaccamento.

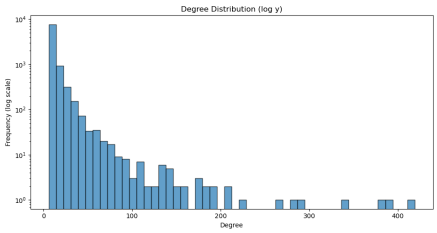
Per questi motivi e da Fig.2a e Fig.2d si evince che la distribuzione dei nodi non è una legge di potenza, ma una distribuzione lognormale, la cui coda è meno ripida e più lunga, tanto da creare una sensibile differenza del grado massimo atteso: 1931 anzichè 419. Una hub del genere, richiederebbe un modello random dell'ordine di 10^5 nodi.

2.3 Path Analysis

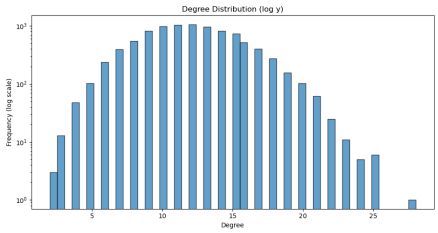
Dal momento che le coppie di nodi disconnesse non sono molto significative ai fini dell'analisi delle interazioni, ci riduciamo, da ora e nel proseguo, alla componente principale connessa del grafo (LCC), mostrata nel dettaglio in Fig.4. In questo caso, il carattere di network reale si



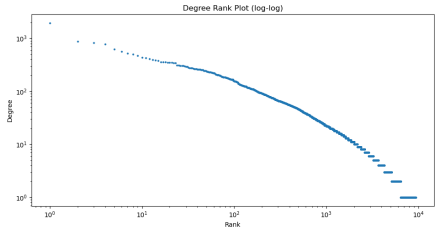
(a) Degree distribution, network reale



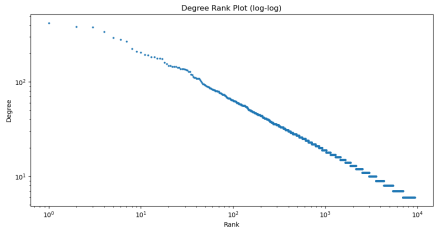
(b) Degree distribution, Barabasi-Albert



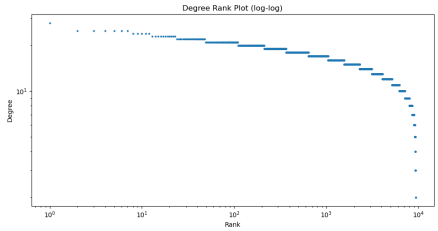
(c) Degree distribution, Erdos-Renyi



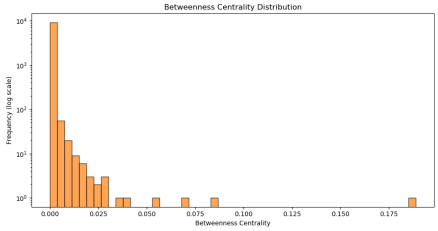
(d) Degree-Rank plot, network reale



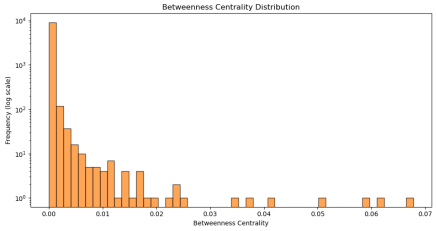
(e) Degree-Rank plot Barabasi-Albert



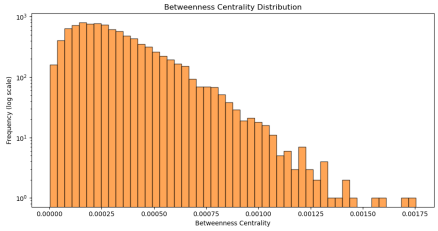
(f) Degree-Rank plot, Erdos-Renyi



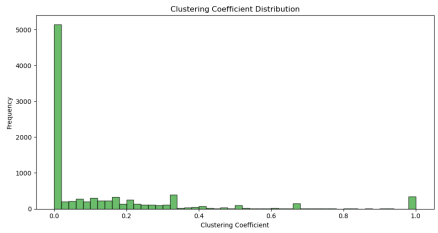
(g) Betweenness centrality, network reale



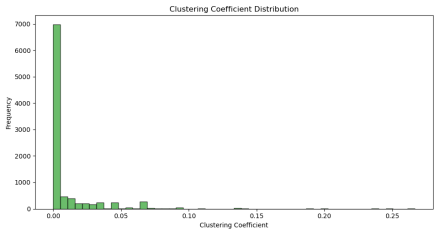
(h) Betweenness centrality, Barabasi-Albert



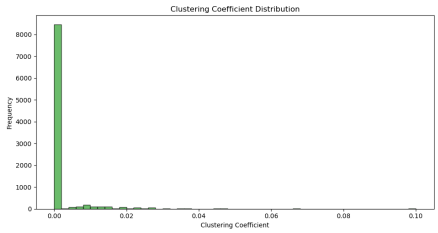
(i) Betweenness centrality, Erdos-Renyi



(j) Clustering coefficient locale, network reale



(k) Clustering coefficient locale, Barabasi-Albert

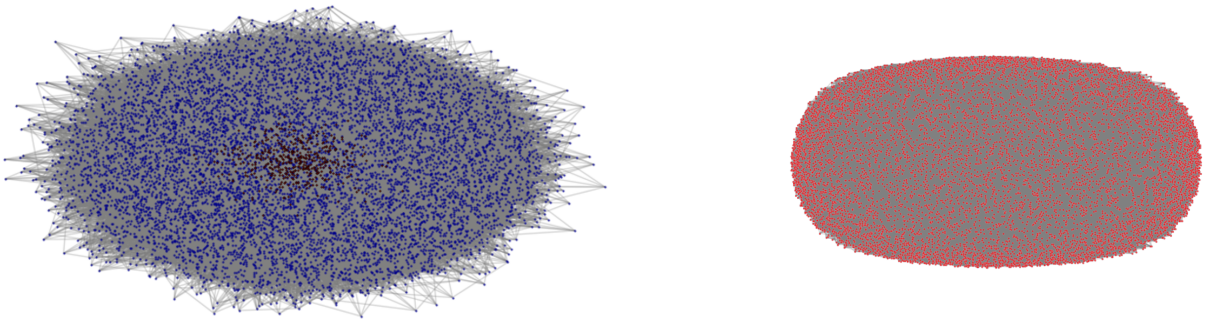


(l) Clustering coefficient locale, Erdos-Renyi

Figure 2: Differenze tra il network reale (sinistra), il random network generato dal modello Barabasi-Albert (centro) e quello con modello Erdos-Renyi (destra).
Si attenziona al fatto che le scale delle ascisse possono essere diverse nei grafici.

Shape of the random BA graph					Shape of the random ER graph		
Nodes	Edges	Edges per step	Discrepancy	Density	Nodes	Edges	Density
9339	55998	6	-676 (1.19%)	0.00128	9339	56674	0.0013
Max degree	Avg. degree		Avg. clustering coeff.		Max degree	Avg. degree	Avg. clustering coeff.
419	11.99		0.0084		28	12.14	0.0014

Table 1: Proprietà dei grafi dei modelli random equivalenti.



(a) (b)

Figure 3: Random network BA (sinistra) e ER (destra), costruiti dalla richiesta di equivalenza con Tab.2. Le hub (i nodi con il 5% più alto di degree) sono evidenziate in rosso.

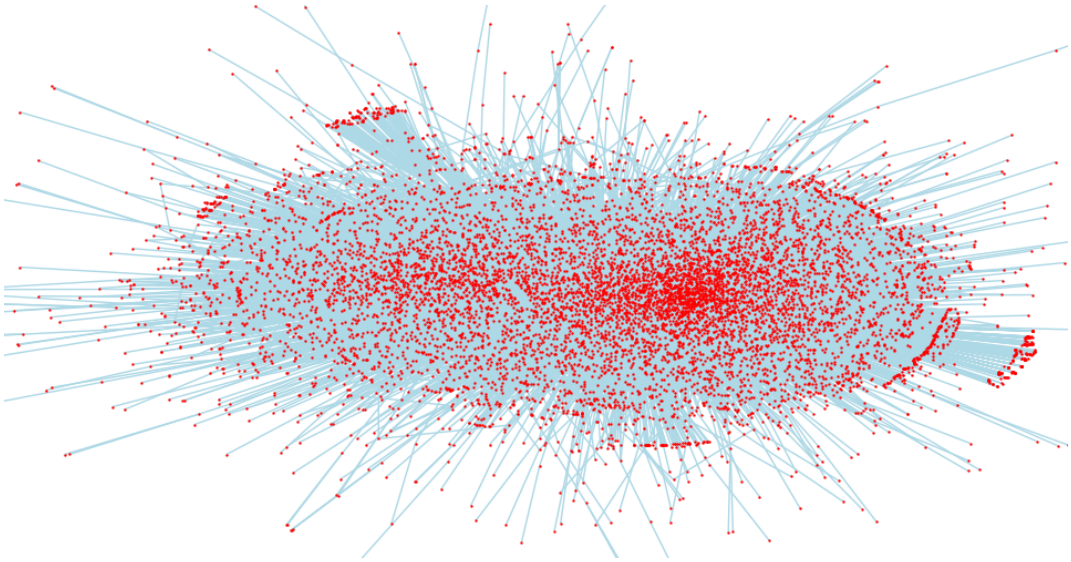


Figure 4: Dettaglio della largest connected component (LCC) del network, comprendente 9267 nodi (il 99.2% dei totali)

riscontra nella bassa distanza media e dalla forma della distribuzione della betweenness (Fig.2g), dove la maggior parte dei nodi hanno bassissima centralità e non esistono veri *bridges* nel network, a causa dell'alto coefficiente di clustering:

Path properties		
Longest shortest	Avg. distance	Max betweenness
10	3.4104	0.187

3 Community Detection

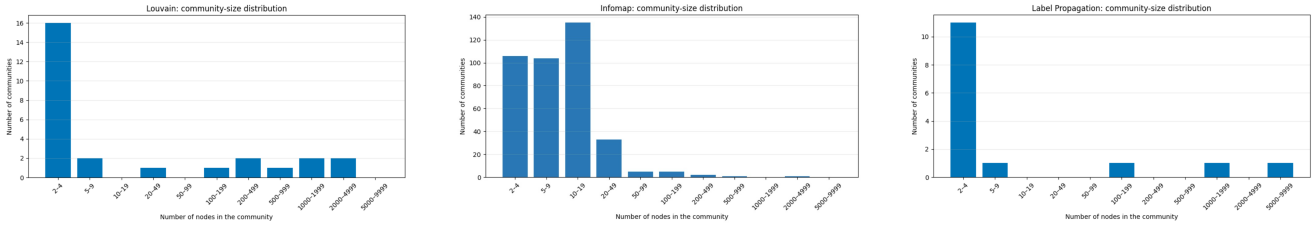
Per identificare la struttura in community della rete ci restringeremo alla **Largest Connected Component (LCC)** e utilizzeremo i seguenti algoritmi, implementati nella libreria *CDlib*: Louvain, Infomap e Label Propagation.

Confronteremo quindi le partizioni ottenute calcolando il numero e la dimensione delle community, oltre alla modularity di Newman–Girvan e la conductance. Queste ultime forniscono una misura diversa della qualità della partizione, in quanto una modularity maggiore indica una maggiore concentrazione degli edges all'interno delle community rispetto al relativo null model, mentre valori inferiori di conductance indicano una migliore separazione delle community dal resto della rete.

3.1 Confronto tra le partizioni e stabilità

I tre algoritmi producono partizioni sensibilmente differenti: la Tab. 2 confronta le loro principali proprietà, mentre in Fig. 5 sono riportate le distribuzioni del numero di community di ognuna.

Ognuno dei tre algoritmi genera una struttura comu-



(a) Louvain (b) Infomap (c) Label Propagation

Figure 5: Distribuzione della community-size per ognuna delle partizioni ottenute dai tre algoritmi.

Algorithm	Communities	Largest	Mean size	Median size	Modularity	Mean conductance
Louvain	27	2317	343.22	4.0	0.3906	0.3613
Infomap	392	3221	23.64	9.0	0.3231	0.6192
Label Prop.	15	8011	617.80	3.0	0.1525	0.2107

Table 2: Confronto delle principali proprietà delle partizioni ottenute dai tre algoritmi.

Algorithm	Num communities	Modularity	Conductance	NMI
Louvain	23 ± 4	0.396 ± 0.005	0.37 ± 0.02	0.52 ± 0.05
Infomap	383 ± 8	0.32 ± 0.01	0.612 ± 0.005	0.84 ± 0.02
Label Propagation	16 ± 2	0.11 ± 0.07	0.22 ± 0.02	0.50 ± 0.35

Table 4: Stabilità dei tre algoritmi attraverso dieci random seed.

nitaria sbilanciata, con poche community numerose e molte costituite da un numero esiguo di nodi. Louvain individua una partizione relativamente più aggregata, caratterizzata dalla modularità più elevata tra le tre partizioni. Infomap produce invece una struttura molto più fine, con 392 community, mentre Label Propagation genera una partizione fortemente sbilanciata: 8011 dei 9267 nodi della LCC vengono infatti assegnati alla stessa community.

Le differenze tra le partizioni sono quantificate tramite la **Normalized Mutual Information (NMI)**, come mostrato in Tab. 3.

Partition 1	Partition 2	NMI
Louvain	Infomap	0.4132
Louvain	Label Propagation	0.2305
Infomap	Label Propagation	0.1804

Table 3: NMI tra le partizioni ottenute dai tre algoritmi.

La maggiore similarità si osserva tra Louvain e Infomap, con una NMI pari a 0.4132, anche se i valori relativamente bassi confermano che i tre algoritmi identificano partizioni tra loro differenti.

I tre algoritmi utilizzati inoltre presentano una componente stocastica nella loro realizzazione, per cui le partizioni che producono dipendono dalla loro particolare inizializzazione.

Per determinare la loro stabilità ripetiamo ogni algoritmo con 10 random seed, quindi valutiamo la variabilità nel numero di communities, nella modularità e nella mean conductance, oltre alla NMI fra le diverse realizzazioni dello stesso algoritmo. In Tab. 4 sono riportati valor medio e deviazione standard dei risultati così ottenuti.

Infomap si rivela il metodo più stabile, in quanto presenta la più alta NMI tra le realizzazioni, oltre a valori di conductance e modularity pressoché costanti nelle partizioni ottenute, dal momento che le deviazioni standard associate risultano molto basse. Louvain sembra produrre partizioni più varie, ma con modularity tra loro molto vicine, mentre Label Propagation presenta una marcata dipendenza dal seed: la NMI è infatti la minore fra le tre e ha una deviazione standard associata nettamente superiore alle altre.

3.2 Validazione semantica

Per valutare se le community individuate rispecchiano anche una qualche organizzazione semantica, associamo a ogni agente un'etichetta data dal **dominant submolt**, ossia il submolt del quale questo presenta il maggior numero di interazioni. Tutti i 9267 nodi della LCC risultano associati ad almeno un dominant submolt, per un totale di 32 etchette.

Confrontiamo quindi le partizioni ottenute mediante i tre algoritmi con quella data dalle etichette semantiche, mediante NMI.

La Tab. 5 riporta i risultati così ottenuti.

Algorithm	NMI with dominant submolt
Louvain	0.0879
Infomap	0.2486
Label Propagation	0.0394

Table 5: NMI tra le partizioni strutturali e i dominant submolts.

Infomap presenta la NMI più alta, mentre Louvain e soprattutto Label Propagation mostrano valori più bassi. Questi risultati però non tengono conto del fatto che Infomap produce un numero molto maggiore di community, di cui molte composte da un numero esiguo di nodi, per cui è più probabile che presenti una più alta compatibilità con le etichette semantiche.

Passiamo quindi a valutare la bontà dell'accordo tra le etichette semantiche e le partizioni strutturali, confrontando queste ultime con un **semantic null model**. Per costruirlo permutiamo randomicamente le etichette dei submolt tra le interazioni, mantenendone inalterata la frequenza complessiva ma eliminandone l'associazione con specifici nodi e interazioni. Effettuiamo un totale di 100 randomizzazioni: per ogni realizzazione cerchiamo il dominant submolt di ogni nodo, quindi calcoliamo la NMI fra le etichette così ottenute e le partizioni strutturali. Confrontando questi risultati con le NMI precedentemente calcolate otteniamo una misura di quanto l'accordo sia migliore rispetto a quello che ci si aspetterebbe per una partizione semantica randomica. In Tab. 6 sono elencati i valori di NMI con le etichette semantiche e con quelle randomizzate, di cui riportiamo valor medio, deviazione standard e valori massimi e minimi nelle 100 randomizzazioni.

Algorithm	Real NMI	Random NMI	Min Rand NMI	Max Rand NMI
Louvain	0.0879	0.016 ± 0.001	0.014	0.019
Infomap	0.2486	0.105 ± 0.002	0.100	0.109
Label Propagation	0.0394	0.0093 ± 0.0009	0.0067	0.0116

Table 6: Confronto tra la NMI osservata e la media ottenuta dal semantic null model.

Si osserva che per ciascuno dei tre algoritmi la real NMI risulta nettamente superiore a quella ottenuta dalle randomizzazioni e che nessuno dei valori massimi della random NMI la raggiunge. Questo ci porta a concludere che i valori di NMI ottenuti, nonostante siano relativamente bassi (soprattutto per Louvain e Label Propagation) descrivono un accordo con le etichette semantiche migliore di quello che ci si aspetterebbe con una partizione semantica randomica.

In questa analisi non abbiamo considerato il fatto che, qualora un nodo presentasse più di un dominant submolt, questo viene scelto randomicamente fra quelli possibili. Per controllare quanto i risultati ottenuti dipendono da questa scelta arbitraria, ricalcoliamo la NMI fra le partizioni strutturali e le etichette semantiche soltanto per i nodi della LCC che presentano un unico dominanti submolt. Si trova che 971 nodi, pari al 10.48% della LCC, presentano almeno un pareggio: ripetendo il confronto sui soli 8296 nodi con dominant submolt univoco, i valori di NMI restano sostanzialmente invariati, come si osserva in Tab. 7.

Algorithm	NMI	NMI - dominant submolt univoco
Louvain	0.0879	0.0922
Infomap	0.2486	0.2613
Label Propagation	0.0394	0.0410

Table 7: Confronto tra la NMI reale e quella ottenuta considerando solo i nodi con dominant submolt univoco.

3.3 Analisi della resolution di Louvain

Per concludere, si nota che Louvain alla risoluzione standard produce una struttura comunitaria molto più aggregata rispetto a quella di Infomap. Per valutare se partizioni più fini rivelano un'organizzazione più articolata, ripetiamo Louvain per sei valori di resolution (pari a 1, 2, 4, 8, 12 e 15). Per ognuno usiamo cinque random seed e valutiamo numero di community, modularità standard, conductance, accordo semantico con i dominant submolts e stabilità tra le realizzazioni.

Resolution	Communities	Modularity	Conductance	Semantic NMI	Stability NMI
1	23.8	0.3940	0.3644	0.0915	0.4926
2	42.4	0.3448	0.6722	0.1367	0.5547
4	132.0	0.2665	0.7734	0.1787	0.6648
8	279.6	0.2045	0.8027	0.2192	0.7748
12	403.4	0.1882	0.8120	0.2428	0.8295
15	481.8	0.1812	0.8163	0.2552	0.8565

Table 8: Risultati medi dell'analisi di sensitivity alla resolution di Louvain.

Dai valori così ottenuti non emerge una resolution ottimale, in quanto all'aumentare di questa le partizioni si fanno più fini, semanticamente più coerenti e più stabili, ma meno favorevoli in termini di modularity e conductance.

È particolarmente significativo il caso di risoluzione pari a 12, per il quale Louvain individua in media 403.4 community con una semantic NMI pari a 0.2428. Questi valori sono molto vicini a quelli ottenuti da Infomap, che individua 392 community con una semantic NMI pari a 0.2486. Ciò suggerisce che parte della differenza osservata tra Louvain e Infomap sia riconducibile alla diversa scala alla quale i due algoritmi descrivono la struttura del network.

3.4 Conclusioni

Nel complesso, l'analisi mostra una struttura comunitaria non riconducibile a un'unica partizione. Louvain alla resolution standard produce una partizione più aggregata e con più alta modularity, mentre Infomap mostra una suddivisione più fine, maggiormente stabile e più coerente con l'organizzazione semantica dei submolt. Label Propagation produce invece una partizione fortemente sbilanciata e dipendente dal seed, oltre che meno in accordo con la distribuzione semantica dei submolt.

In ognuno dei tre casi inoltre il confronto con il semantic null model rivela un'associazione con i submolt superiore a quella ottenuta randomizzando le etichette. Nel loro insieme, questi risultati sono compatibili con una struttura comunitaria *multiscale*, nella quale differenti algoritmi e differenti valori di resolution evidenziano livelli diversi di organizzazione della rete.

4 Dynamic Analysis

---

5 Open Questions